

# MCD-ST

## Modèle Commun de Données en Santé au Travail

*Standardisation, contrôle qualité et cohorting des données des SPSTi*

### 2.1. Présentation du projet

MCD-ST, pour Modèle Commun de Données en Santé au Travail, est un projet de développement, de validation et de documentation d'un outil open source destiné aux Services de Prévention et de Santé au Travail Interentreprises. Le projet vise à transformer des exports hétérogènes issus de logiciels métiers SPSTi en tables standardisées, contrôlées, documentées et exploitables pour la constitution de cohortes reproductibles, l'évaluation d'actions de prévention et la conduite de travaux de recherche ou d'appui au pilotage en santé au travail.

Le projet ne consiste pas à créer une base nationale centralisée, ni à remplacer les logiciels métiers existants. Il propose une couche logicielle réutilisable : un modèle commun de données, un pipeline de transformation, un moteur de contrôle qualité, un moteur de cohorting et un jeu de données synthétiques permettant la démonstration et les tests sans publication de données réelles.

Le projet relève de la thématique 3 de l'AMI BOAS : développement, validation et sophistication de programmes visant à faciliter la réutilisation de données de santé autres que celles issues de la base principale du SNDS. Les données concernées sont les données produites dans le cadre des missions des SPSTi : suivi individuel, visites santé-travail, postes, expositions professionnelles, conclusions médicales, actions en milieu de travail et événements de prévention de la désinsertion professionnelle.

| Élément                    | Description                                                                                                                     |
|----------------------------|---------------------------------------------------------------------------------------------------------------------------------|
| Acronyme                   | MCD-ST                                                                                                                          |
| Titre complet              | Modèle Commun de Données en Santé au Travail pour la standardisation, le contrôle qualité et le cohorting des données des SPSTi |
| Thématique BOAS            | Thématique 3                                                                                                                    |
| Nature                     | Développement, validation, documentation et mise à disposition open source d'un programme de réutilisation de données SPSTi     |
| Durée                      | 24 mois                                                                                                                         |
| Financement demandé        | 100 000 €                                                                                                                       |
| Résultat principal attendu | Package open source permettant d'importer, transformer, contrôler et interroger des données SPSTi standardisées                 |
| Public bénéficiaire        | SPSTi, équipes de recherche, épidémiologistes, data managers, équipes prévention, institutions publiques ou parapubliques       |

### 2.2. Objectifs et finalité de(s) algorithme(s) ou outil(s) concerné(s)

#### 2.2.1. Contexte

Les SPSTi produisent quotidiennement des données à forte valeur de santé publique : informations sur les postes, visites, expositions, conclusions médicales, aménagements, restrictions, orientations de maintien en emploi et actions en milieu de travail. Ces données sont longitudinales, proches du terrain et directement reliées aux situations réelles de travail.

Malgré cette richesse, leur réutilisation reste limitée. Les formats d'export varient selon les logiciels métiers, les nomenclatures sont souvent locales, les intitulés de postes et d'expositions sont hétérogènes, les textes courts sont nombreux et les transformations appliquées aux données ne sont pas toujours documentées. Cette situation freine la constitution de cohortes multicentriques, la comparaison entre SPSTi, l'évaluation d'actions de prévention et la production d'indicateurs agrégés fiables.

MCD-ST répond à ce problème en proposant un socle commun, documenté et auditable. L'objectif est d'éviter la multiplication de scripts locaux non réutilisables et de fournir à la communauté un outil partagé de transformation et de qualité des données santé-travail.

Le projet intégrera un module de datavisualisation open source, MCD-ST Viz, destiné à faciliter l'exploration, le contrôle qualité et la constitution de cohortes à partir des données standardisées. Ce module permettra de produire des tableaux de bord agrégés sur la complétude et la cohérence des données, la répartition des visites, des expositions professionnelles, des restrictions, des aménagements, des actions en milieu de travail et des événements de prévention de la désinsertion professionnelle. Il générera également des diagrammes de flux documentant les étapes d'inclusion et d'exclusion des cohortes, afin d'améliorer la transparence, la reproductibilité et la réutilisation des analyses. Les visualisations seront produites uniquement sur données agrégées ou synthétiques dans les livrables ouverts, sans publication de données personnelles.

2.2.2. Question de recherche / problématique médicale et technique

La problématique peut être formulée ainsi : comment transformer des données SPSTi hétérogènes, issues de systèmes d'information différents, en un modèle commun de données suffisamment standardisé, documenté et contrôlé pour permettre la réutilisation fiable de ces données dans des travaux de recherche, de prévention et d'évaluation ?

Cette problématique combine une dimension médicale et une dimension technique. La dimension médicale porte sur la représentation correcte d'objets métier propres à la santé au travail : visite de reprise, visite de pré-reprise, exposition professionnelle, restriction, aménagement, inaptitude, action en milieu de travail ou événement de prévention de la désinsertion professionnelle. La dimension technique porte sur la capacité à importer, mapper, contrôler, tracer et requêter ces objets dans un format commun, tout en respectant les contraintes de confidentialité.

2.2.3. Objectifs des programmes et finalités opérationnelles

L'objectif principal est de développer, documenter et valider un modèle commun de données en santé au travail et les programmes open source associés permettant la standardisation et la réutilisation de données issues des SPSTi.

- Définir un dictionnaire de données commun couvrant un socle minimal santé-travail : travailleurs pseudonymisés, employeurs, postes, visites, expositions, conclusions, actions de prévention et événements PDP.
- Développer un package logiciel d'import, de transformation et d'export vers le modèle MCD-ST.
- Documenter les règles de mapping entre données sources et tables cibles dans des fichiers de configuration YAML produit par les assistants de mapping.
- Mettre en œuvre un moteur de contrôle qualité automatisé.
- Développer un moteur de constitution de cohortes reproductibles, fondé sur des définitions versionnées.
- Produire des données synthétiques réalistes permettant de tester et démontrer l'outil sans exposition de données réelles.
- Évaluer la performance du modèle et des pipelines sur plusieurs SPSTi pilotes.
- Publier le code, les prétraitements, la documentation médicale, technique et méthodologique sous licence permissive.

2.2.4. Intérêt de l'outil proposé

L'intérêt du projet est à la fois opérationnel, scientifique et institutionnel. Pour les SPSTi, MCD-ST fournit une méthode robuste pour exploiter leurs données sans dépendre d'extractions ad hoc. Pour les équipes de recherche, il facilite la création de cohortes santé-travail documentées et reproductibles. Pour les institutions, il permet d'envisager des indicateurs agrégés plus homogènes, sans centraliser ni publier de données individuelles.

| Bénéfice         | Description                                                                                                                  |
|------------------|------------------------------------------------------------------------------------------------------------------------------|
| Réutilisation    | Un même modèle cible peut être alimenté par plusieurs SPSTi grâce à des assistants de mappings automatisés et configurables. |
| Qualité          | Les erreurs, valeurs manquantes, incohérences temporelles et mappings inconnus sont explicitement tracés.                    |
| Reproductibilité | Chaque cohorte est définie par un fichier versionné et peut être régénérée sur les mêmes données.                            |

| Bénéfice        | Description                                                                                                           |
|-----------------|-----------------------------------------------------------------------------------------------------------------------|
| Confidentialité | Les livrables open source ne contiennent pas de données réelles ; les tests reposent sur des données synthétiques.    |
| Mutualisation   | Le code, les schémas, les exemples et la documentation sont ouverts à la revue et à l'amélioration par la communauté. |

## 2.3. Présentation de la démarche

### 2.3.1. Développement de l'algorithme et sophistication technique

Le développement reposera sur une architecture en cinq couches : zone brute, mapping, tables MCD-ST, contrôle qualité et cohorting. Cette architecture permet de conserver la traçabilité de bout en bout et d'éviter les corrections silencieuses.

Exports SPSTi contrôlés

- > Zone RAW : conservation des fichiers sources
- > Mapping YAML : correspondances source-cible et règles de normalisation
- > Tables MCD-ST : données standardisées exportables en Parquet ou SQL
- > Contrôle qualité : règles, alertes, rapport HTML/JSON
- > Cohorting : définitions versionnées, requêtes, diagrammes de flux

| Couche        | Fonction                                                                 | Livrable logiciel                                   |
|---------------|--------------------------------------------------------------------------|-----------------------------------------------------|
| RAW           | Importer et conserver les exports sources sans correction silencieuse    | Importeurs CSV, Excel, Parquet                      |
| Mapping       | Décrire les correspondances source-cible de manière déclarative          | Fichiers YAML et moteur de transformation           |
| Modèle commun | Stocker les données standardisées dans les tables MCD-ST                 | Tables exportables en Parquet ou SQL                |
| Qualité       | Détecter doublons, valeurs manquantes, incohérences et mappings inconnus | Rapport HTML/JSON et table d'anomalies              |
| Cohorting     | Créer des cohortes reproductibles à partir de définitions versionnées    | Moteur de requêtes, diagrammes de flux, métadonnées |

Les mappings seront produits par les assistants de mapping et externalisés dans des fichiers YAML afin de permettre l'adaptation à différents logiciels métiers et à différents formats d'export. Le code ne dépendra pas d'un fournisseur logiciel particulier. Le même moteur de transformation pourra être utilisé par un autre SPSTi en adaptant uniquement le fichier de configuration source-cible.

```
source_system: SPSTI_A
person:
  source_file: raw_salaries.csv
  fields:
    person_id:
      source: id_salarie
      transform: hash_id
      prefix: P
    birth_year:
      source: annee_naissance
      type: integer
occupational_visit:
  source_file: raw_visites.csv
  fields:
    visit_type_code:
      source: type_visite
    values:
      reprise: REPRISE
      pre-reprise: PRE_REPRISE
      periodique: VIP_PERIODIQUE
```

| Table MCD-ST  | Unité d'observation         | Rôle                                                                      |
|---------------|-----------------------------|---------------------------------------------------------------------------|
| personne      | Travailleur pseudonymisé    | Décrire les caractéristiques minimales nécessaires aux analyses agrégées. |
| employeur     | Entreprise ou établissement | Décrire le contexte professionnel agrégé : secteur, taille, région.       |
| episode_poste | Période de poste            | Relier un travailleur à un poste, une entreprise et une période.          |

| Table MCD-ST        | Unité d'observation         | Rôle                                                                             |
|---------------------|-----------------------------|----------------------------------------------------------------------------------|
| visite_st           | Visite santé-travail        | Décrire les visites, motifs, dates et types de professionnels.                   |
| conclusion_medicale | Conclusion de visite        | Standardiser aptitudes, restrictions, aménagements, inaptitudes et orientations. |
| exposition_pro      | Exposition professionnelle  | Standardiser nuisances, agents et catégories d'exposition.                       |
| action_prevention   | Action en milieu de travail | Documenter les actions collectives ou interventions en entreprise.               |
| evenement_pdp       | Événement PDP               | Suivre les événements liés à la prévention de la désinsertion professionnelle.   |
| trace_source        | Trace source-cible          | Documenter la provenance, les versions et les transformations appliquées.        |
| anomalie_qualite    | Anomalie de qualité         | Consigner les problèmes détectés par le moteur qualité.                          |

Afin de faciliter l'installation, le test et la réutilisation du package MCD-ST par d'autres SPSTi ou équipes de recherche, le projet prévoit la mise à disposition d'un environnement d'exécution dockerisé. Cet environnement permettra de lancer le pipeline complet — import, mapping automatisé, contrôle qualité, génération de données synthétiques et cohorting — sans configuration complexe de l'environnement local. La dockerisation contribuera à garantir la reproductibilité des traitements, à limiter les problèmes de dépendances logicielles et à faciliter l'évaluation du projet par des tiers.

### Module IA optionnel

Un module optionnel d'aide à la structuration des textes courts pourra être développé si le corpus annoté disponible est suffisant. Ce module ne conditionne pas la réussite du socle MCD-ST. Il vise uniquement à améliorer la normalisation d'intitulés de postes, de nuisances, de restrictions ou de motifs de visite. Il ne produit aucune décision médicale automatisée.

- Approche hybride : règles expertes, règles lexicales, appariement sémantique et classification supervisée si les données annotées le permettent.
- Sortie systématiquement accompagnée d'un score de confiance, de la méthode utilisée et d'un indicateur de revue humaine.
- Désactivation possible sans altérer le fonctionnement du modèle commun.
- Validation par comparaison à des annotations expertes et à des méthodes de référence simples.

### 2.3.2. Méthodologie d'évaluation et maintenance

L'évaluation combinera des tests automatisés, une validation technique sur données synthétiques et pilotes, ainsi qu'une validation métier par annotation experte. La maintenance reposera sur un versioning sémantique, des tests de non-régression et une documentation continue des changements de schéma et de nomenclatures.

| Indicateur                              | Cible                     | Méthode de mesure                                              |
|-----------------------------------------|---------------------------|----------------------------------------------------------------|
| Taux de champs sources importés         | ≥ 95 %                    | Comparaison dictionnaire source / tables MCD-ST                |
| Taux d'erreurs bloquantes après mapping | < 2 %                     | Rapport qualité automatisé                                     |
| Reproductibilité du pipeline            | 100 %                     | Relance sur mêmes entrées et comparaison des sorties           |
| Traçabilité des transformations         | 100 % des tables cibles   | Présence de métadonnées source, version, date et configuration |
| Exécution sur données synthétiques      | 100 % des tests critiques | Tests automatisés CI/CD                                        |

Les règles qualité couvriront notamment l'unicité des identifiants pseudonymisés, la cohérence temporelle, les valeurs hors nomenclature, les expositions non rattachées, les conclusions sans visite associée et la traçabilité des critères d'inclusion et d'exclusion des cohortes.

### 2.3.3. Stratégie de validation externe

La validation externe sera conduite sur deux à trois SPSTi pilotes ayant des logiciels métiers différents du notre, il existe 4 plateforme principalement sur le marché). Chaque SPSTi fournira un export pseudonymisé ou un export réduit conforme aux règles définies avec le DPO. L'objectif n'est pas de comparer les SPSTi entre eux, mais de vérifier que le même modèle MCD-ST peut être alimenté par des sources hétérogènes avec un niveau de qualité mesurable.

| Objet annoté               | Volume cible approx. | Experts mobilisés                           | Métriques                           |
|----------------------------|----------------------|---------------------------------------------|-------------------------------------|
| Types de visite            | 200 à 300            | Médecin du travail, infirmier santé travail | Précision, matrice de confusion     |
| Postes / métiers           | 200 à 500            | Médecin du travail, IPRP                    | Précision top-1/top-3               |
| Expositions                | 200 à 500            | IPRP, médecin du travail                    | Précision, rappel, F1-score         |
| Conclusions / restrictions | 100 à 200            | Médecin du travail                          | Précision, rappel                   |
| Cohortes pilotes           | 3 à 5 cohortes       | Binôme métier-data                          | Concordance avec extraction experte |

### 2.3.4. Documentation de l'algorithme

La documentation sera produite en deux niveaux complémentaires. Le premier niveau, technique, décrira l'installation, la structure du dépôt, les dépendances, les formats d'entrée, les fichiers YAML, les tables cibles, les commandes d'exécution, les tests et les erreurs connues. Le second niveau, médical et métier, décrira les objets santé-travail représentés, les définitions retenues, les nomenclatures, les limites et les conditions d'usage.

| Documentation           | Contenu prévu                                                                    | Format                   |
|-------------------------|----------------------------------------------------------------------------------|--------------------------|
| Spécification MCD-ST    | Tables, champs, types, nomenclatures, relations                                  | Markdown / HTML / PDF    |
| Guide technique         | Installation, API, commandes, exemples, tests                                    | MkDocs                   |
| Guide médical et métier | Définitions santé-travail, règles de codage, limites                             | PDF / HTML               |
| Guide de mapping        | Méthode d' utilisation de l'assiatnt de mapping automatisé pour un nouveau SPSTi | Markdown / exemples YAML |
| Rapport de validation   | Métriques, protocole, limites, reproductibilité                                  | PDF / HTML               |
| Fiche réutilisation     | Conditions d'usage, licence, périmètre, données synthétiques                     | README / annexe          |

### 2.3.5. Caractère innovant et valeur ajoutée

La valeur ajoutée du projet n'est pas de proposer un modèle prédictif isolé, mais de créer un socle réutilisable dans un domaine où la donnée est riche mais peu standardisée. MCD-ST transforme un problème récurrent de data management en actif open source mutualisable. Le projet fournit ainsi un chaînon manquant entre les données terrain des SPSTi et les besoins de recherche, d'évaluation et de pilotage.

L'innovation principale tient à l'adaptation d'une logique de modèle commun de données au domaine de la santé au travail, avec prise en compte d'objets métier spécifiques : exposition professionnelle, action en milieu de travail, visite de pré-reprise, restriction, aménagement, événement PDP et traçabilité source-cible. Le projet est conçu pour rester **indépendant des logiciels métiers** et pour permettre une validation externe entre SPSTi.

## 2.4. Données mobilisées

### 2.4.1. Description du périmètre de données

Les données mobilisées sont des données issues des SPSTi et non des données de la base principale du SNDS. Les entrées de la V1 seront des exports contrôlés, pseudonymisés et minimisés. La publication open source portera exclusivement sur le code, les schémas, les mappings génériques, la documentation, les jeux synthétiques et les protocoles de validation.

| Domaine                      | Exemples de données                                                    | Statut V1            |
|------------------------------|------------------------------------------------------------------------|----------------------|
| Travailleurs pseudonymisés   | Identifiant pseudonyme, année de naissance, sexe, statut de suivi      | Inclus               |
| Employeur / établissement    | Identifiant pseudonyme, secteur NAF, taille, localisation agrégée      | Inclus               |
| Poste / emploi               | Intitulé de poste, famille métier, code PCS si disponible, dates       | Inclus               |
| Visites santé-travail        | Type de visite, date, motif, professionnel, rattachement travailleur   | Inclus               |
| Expositions professionnelles | Nuisance, agent, catégorie, intensité si disponible, source            | Inclus               |
| Conclusions médicales        | Aptitude, restriction, aménagement, inaptitude, orientation            | Inclus               |
| Actions en milieu de travail | Étude de poste, fiche d'entreprise, sensibilisation, action collective | Inclus si disponible |
| PDP / maintien en emploi     | Pré-reprise, orientation cellule PDP, aménagement, reclassement        | Inclus               |

| Domaine                            | Exemples de données                                             | Statut V1           |
|------------------------------------|-----------------------------------------------------------------|---------------------|
| Textes libres courts               | Intitulé de poste, nuisance, conclusion courte, motif de visite | Optionnel et limité |
| Documents PDF / courriers complets | Courriers médicaux, documents non structurés                    | Exclus V1           |

## 2.4.2. Description des modalités d'appariement

Aucun appariement avec la base principale du SNDS n'est prévu dans la V1. Le projet n'appelle donc pas d'expression de besoin SNDS. Les rapprochements nécessaires au fonctionnement du modèle seront internes aux exports SPSTi : rattachement d'une visite à un travailleur pseudonymisé, d'une exposition à un épisode de poste, d'une conclusion à une visite, ou d'une action de prévention à un employeur ou un établissement.

Les identifiants sources ne seront pas publiés. Les identifiants techniques utilisés dans les tables MCD-ST seront pseudonymisés par un mécanisme sécurisé défini avec le DPO du porteur. Lorsque les SPSTi pilotes testeront l'outil, chaque environnement conservera la maîtrise de ses propres données ; le projet ne nécessite pas de constitution d'une base centralisée commune.

## 2.4.3. Identification des limites, risques et enjeux de mobilisation

| Limite ou risque                 | Effet possible                                        | Mesure de maîtrise                                                                      |
|----------------------------------|-------------------------------------------------------|-----------------------------------------------------------------------------------------|
| Hétérogénéité des exports        | Mappings multiples et maintenance accrue              | Fichiers YAML paramétrables, périmètre V1 limité, documentation des écarts              |
| Qualité variable des champs      | Cohortes incomplètes ou biaisées                      | Rapport qualité, indicateurs de complétude et règles bloquantes/avertissements          |
| Nomenclatures locales            | Difficulté de comparaison entre SPSTi                 | Nomenclature cible minimale et tables de correspondance source-cible                    |
| Textes libres sensibles          | Risque de confidentialité et difficulté de validation | Traitement optionnel, contrôlé, non publié ; données synthétiques pour l'open source    |
| Accès tardif aux données pilotes | Décalage du calendrier de validation                  | Données synthétiques disponibles dès M1 ; exports pilotes réduits au minimum nécessaire |

## 2.5. Faisabilité et réalisme technique

### 2.5.1. Calendrier du projet

Le projet est prévu sur 24 mois, conformément au plafond de durée max de la thématique 3. Le calendrier ci-dessous reprend la structuration du budget joint et articule les jalons techniques, métiers et open source.

| Phase                              | Mois    | Objectifs                                           | Livrables / jalons               | Budget associé |
|------------------------------------|---------|-----------------------------------------------------|----------------------------------|----------------|
| Phase 1 — Cadrage                  | M1-M2   | Gouvernance, périmètre, données sources, conformité | Dossier de cadrage validé        | 8 000 €        |
| Phase 2 — Modèle commun            | M3-M5   | Tables, champs, nomenclatures, règles source-cible  | Spécification MCD-ST v0.1        | 17 000 €       |
| Phase 3 — Développement ETL        | M6-M12  | Connecteurs, transformations, traçabilité, exports  | Package ETL v0.1                 | 25 000 €       |
| Phase 4 — Qualité et cohorting     | M13-M16 | Règles qualité, cohortes pilotes, rapports          | Moteur qualité + cohorting       | 20 000 €       |
| Phase 5 — Validation multi-SPSTi   | M17-M21 | Tests, annotation experte, métriques                | Rapport de validation provisoire | 18 000 €       |
| Phase 6 — Finalisation open source | M22-M24 | Documentation, publication, communication           | Version 1.0 publiée              | 12 000 €       |

### 2.5.2. Risques anticipés

| Risque                                    | Probabilité | Impact | Mesure de maîtrise                                                       |
|-------------------------------------------|-------------|--------|--------------------------------------------------------------------------|
| Hétérogénéité excessive des exports SPSTi | Élevée      | Élevé  | Mappings YAML automatisés, périmètre V1 limité, documentation des écarts |
| Qualité insuffisante de certains champs   | Élevée      | Moyen  | Rapport qualité, seuils d'alerte, transparence des limites               |

| Risque                                   | Probabilité | Impact         | Mesure de maîtrise                                                                         |
|------------------------------------------|-------------|----------------|--------------------------------------------------------------------------------------------|
| Accès tardif aux données pilotes         | Moyenne     | Élevé          | Données synthétiques dès M1, exports pilotes réduits, procédure d'accès anticipée          |
| Charge de validation métier sous-estimée | Moyenne     | Moyen          | Échantillons limités, grille d'annotation simple, adjudication experte                     |
| Risque RGPD / confidentialité            | Moyenne     | Élevé          | Pseudonymisation, minimisation, absence de données réelles en open source, implication DPO |
| Module IA insuffisamment performant      | Moyenne     | Faible à moyen | Module optionnel, baselines, seuils de confiance, revue humaine                            |
| Adoption limitée après projet            | Moyenne     | Moyen          | Guide d'implémentation, données synthétiques, exemples et documentation claire             |

### 2.5.3. Démarches réglementaires et accès aux données

Les démarches réglementaires seront finalisées avec le DPO du porteur et les SPSTi pilotes. Le projet appliquera les principes de minimisation, pseudonymisation, cloisonnement des environnements et documentation des traitements. Les données réelles ne seront jamais publiées dans le dépôt open source.

- Qualification juridique du traitement et inscription au registre des traitements du porteur.
- Analyse des risques et, si nécessaire, réalisation d'une analyse d'impact relative à la protection des données.
- Définition d'une convention ou procédure de mise à disposition d'exports pilotes entre le porteur et les SPSTi participants.
- Limitation des données aux variables strictement nécessaires au développement et à la validation.
- Utilisation de données synthétiques pour les tests publics, les exemples et la documentation open source.
- Absence d'appariement SNDS prévu en V1 ; annexe EDB SNDS non applicable.

### 2.5.4. Budget

Le montant demandé à la Plateforme des Données de Santé est de 100 000 €, correspondant au plafond indicatif de la thématique 3. Le budget détaillé est fourni dans le tableur joint et résumé ci-dessous.

| Poste budgétaire                               | Catégorie            | Mois    | Montant demandé | Justification                                          |
|------------------------------------------------|----------------------|---------|-----------------|--------------------------------------------------------|
| Data engineering / développement logiciel      | Frais de personnel   | M1-M24  | 40 000 €        | Schéma CDM, ETL, packaging, tests, CI/CD               |
| Data science / biostatistique                  | Frais de personnel   | M3-M15  | 20 000 €        | Contrôles qualité, cohorting, validation quantitative  |
| Expertise médicale santé-travail               | Frais de personnel   | M1-M24  | 15 000 €        | Définitions métier, validation médicale, annotation    |
| Documentation et data management               | Frais de personnel   | M1-M24  | 10 000 €        | Dictionnaire, guide technique, guide médical, exemples |
| Annotation et validation experte               | Prestations          | M10-M15 | 7 000 €         | Jeux annotés, adjudication, validation métier          |
| Conformité, sécurité, RGPD                     | Prestations          | M1-M6   | 3 000 €         | DPO, juriste, procédures, analyse de risques           |
| Infrastructure, tests, publication open source | Autres coûts directs | M1-M24  | 3 000 €         | Outillage, CI/CD, environnements de test               |
| Communication et dissémination                 | Autres coûts directs | M22-M24 | 2 000 €         | Webinaire, supports, valorisation écosystème           |
| TOTAL                                          |                      |         | 100 000 €       | Budget plafond thématique 3                            |

Répartition par catégorie : frais de personnel 85 000 € (85 %), prestations 10 000 € (10 %), autres coûts directs 5 000 € (5 %), soit un total de 100 000 €.

### 2.5.5. Modalités de financement

Le financement demandé correspond à une subvention de 100 000 € au titre de l'AMI BOAS thématique 3. Les travaux associés à la demande d'aide n'auront pas commencé avant la signature de la convention de collaboration. Le porteur confirmera avant dépôt que l'assiette de travaux proposée ne fait pas l'objet d'un autre financement public couvrant les mêmes dépenses.

Les justificatifs attendus seront préparés conformément aux catégories budgétaires : frais de personnel affectés au projet, prestations sur factures, autres coûts directs et coûts de communication strictement liés au projet. Le suivi budgétaire sera intégré au comité de pilotage trimestriel.



## 2.6. Accompagnement demandé à la Plateforme des Données de Santé

L'accompagnement demandé à la Plateforme des Données de Santé porte sur le cadrage, la conformité, la valorisation open source et la mise en relation avec l'écosystème des données de santé. Le projet ne demande pas d'accès à la base principale du SNDS en V1.

| Besoin d'accompagnement | Description                                                                                                               |
|-------------------------|---------------------------------------------------------------------------------------------------------------------------|
| Cadrage réglementaire   | Appui à la qualification des démarches réglementaires et à la documentation des traitements.                              |
| Cadrage technique       | Conseil sur les standards de documentation, l'architecture open source, les tests et la reproductibilité.                 |
| Préparation des données | Retours méthodologiques sur l'extraction, la structuration, la qualification et la standardisation des données SPSTi.     |
| Mise en relation        | Mise en relation avec des acteurs développant des outils comparables de data management, cohorting ou qualité de données. |
| Valorisation            | Appui à la communication, à la fiche projet grand public et à la diffusion dans la BOAS si le projet est retenu.          |

## 2.7. Caractère réutilisable de l'algorithme

### 2.7.1. Démonstration de la réutilisabilité

La réutilisabilité est le principe directeur du projet. MCD-ST est conçu pour être appliqué à plusieurs SPSTi sans réécriture du code : les adaptations locales sont portées par des fichiers de mapping créés automatiquement, des tables de correspondance et des nomenclatures configurables.

- Réutilisation technique : package installable, API documentée, commandes en ligne, tests automatisés.
- Réutilisation sémantique : dictionnaire de données, nomenclatures, définitions métier et règles de correspondance documentées.
- Réutilisation scientifique : cohortes décrites par des fichiers versionnés et diagrammes de flux reproductibles.
- Réutilisation pédagogique : données synthétiques et exemples complets permettant de tester le pipeline sans données sensibles.
- Réutilisation institutionnelle : possibilité de produire des indicateurs agrégés homogènes à partir de données standardisées localement.

### 2.7.2. Modalités de mise à disposition en open source

Les livrables seront publiés dans un dépôt Git public, sous licence Apache 2.0, après validation des éléments diffusables. Le dépôt ne contiendra aucune donnée réelle. Il contiendra le code source, les schémas, les fichiers de configuration génériques, les données synthétiques, les tests, la documentation et les rapports de validation.

| Élément ouvert          | Contenu                                                                      |
|-------------------------|------------------------------------------------------------------------------|
| Code source             | ETL, mapping, qualité, cohorting, génération de données synthétiques         |
| Prétraitements          | Nettoyage, typage, normalisation, pseudonymisation paramétrable, traçabilité |
| Documentation technique | Installation, dépendances, commandes, API, exemples                          |
| Documentation médicale  | Définitions santé-travail, nomenclatures, limites, conditions d'usage        |
| Méthode d'évaluation    | Protocole, métriques, résultats agrégés et limites                           |
| Données synthétiques    | Jeux d'exemple sans données personnelles permettant les tests publics        |

### 2.7.3. Pérennisation et mise à jour

La pérennisation reposera sur une gouvernance de maintenance légère mais explicite : versioning sémantique, journal des changements, tests de non-régression, revue des contributions, documentation des évolutions de nomenclatures et animation d'un réseau de SPSTi utilisateurs pilotes.

- Publication d'une version 1.0 à M24 avec documentation stable.
- Mise en place d'un fichier CHANGELOG et d'un processus de revue des contributions.



- Maintien d'un jeu synthétique de référence pour tester les futures versions.
- Organisation d'un webinaire de restitution et d'une session technique d'appropriation.
- Identification d'un référent technique et d'un référent métier pour arbitrer les évolutions post-projet.

## 2.8. Intégration du projet dans une démarche open source

Le projet sera développé selon une logique open source dès la conception, et non comme une ouverture tardive. La structure du dépôt, les tests, la documentation et les exemples seront pensés pour permettre à un tiers de comprendre, exécuter et adapter l'outil.

| Composant          | Description                                                                                        |
|--------------------|----------------------------------------------------------------------------------------------------|
| Dépôt Git          | Organisation claire du code, branches de développement, issues, pull requests, tags de version.    |
| Licence            | Apache 2.0 ou MIT, choix final à valider par le porteur.                                           |
| Tests              | Tests unitaires, tests d'intégration, exécution sur données synthétiques, CI/CD.                   |
| Documentation      | README, guide d'installation, tutoriels, références des tables et exemples de cohortes.            |
| Qualité logicielle | Linting, formatage, typage progressif, revue de code.                                              |
| Accessibilité      | Exemples simples, commandes reproductibles, jeu de données synthétique et fiches de prise en main. |

## 2.9. Soumissions précédentes

Aucune soumission précédente du projet MCD-ST à l'AMI BOAS n'est connue à la date de préparation du présent dossier. Ce point devra être confirmé par le porteur avant dépôt sur démarches-simplifiées.

## 2.10. Annexes à joindre au dossier

Les annexes ci-dessous sont intégrées dans le présent document ou référencées comme pièces jointes à déposer. L'annexe financière détaillée reste le tableur Excel Budget\_MCD-ST\_BOAS\_T3.xlsx.

| Annexe                                           | Statut                             | Observation                                                |
|--------------------------------------------------|------------------------------------|------------------------------------------------------------|
| Annexe 1 — Présentation du projet / fiche projet | Incluse ci-dessous                 | Fiche synthétique et fiche grand public.                   |
| Annexe 2 — Présentation de l'équipe mobilisée    | Incluse ci-dessous                 | À compléter avec noms, structures et lettres d'engagement. |
| Annexe 3 — Grille de financement                 | Pièce jointe Excel + résumé inclus | Budget_MCD-ST_BOAS_T3.xlsx.                                |
| Annexe 4 — EDB SNDS                              | Non applicable en V1               | Aucun accès à la base principale du SNDS n'est demandé.    |
| Annexe 5 — Références et documents sources       | Incluse ci-dessous                 | Références regroupées en annexe conformément à la notice.  |

## Annexe 1 — Présentation du projet / fiche projet

| Rubrique            | Réponse                                                                                                                        |
|---------------------|--------------------------------------------------------------------------------------------------------------------------------|
| Nom du projet       | MCD-ST — Modèle Commun de Données en Santé au Travail                                                                          |
| Résumé court        | Boîte à outils open source pour standardiser, contrôler et réutiliser des données SPSTi sous forme de cohortes reproductibles. |
| Problème traité     | Hétérogénéité des exports, nomenclatures locales, faible interopérabilité et documentation insuffisante des transformations.   |
| Solution proposée   | Modèle commun de données, ETL configurable, moteur qualité, moteur de cohorting, données synthétiques et documentation.        |
| Public bénéficiaire | SPSTi, chercheurs, épidémiologistes, data managers, équipes prévention, institutions.                                          |

| Rubrique           | Réponse                                                           |
|--------------------|-------------------------------------------------------------------|
| Livrable principal | Package open source MCD-ST version 1.0 et documentation associée. |

## Fiche projet grand public

Chaque jour, les Services de Prévention et de Santé au Travail accompagnent les salariés et recueillent des informations utiles pour mieux prévenir les risques professionnels : expositions au bruit, aux produits chimiques, aux postures contraignantes, aux gestes répétitifs, aux horaires atypiques ou aux situations pouvant conduire à une désinsertion professionnelle.

Aujourd'hui, ces informations sont difficiles à réutiliser car chaque service peut utiliser ses propres outils, ses propres formats et ses propres manières de décrire les situations de travail. Le projet MCD-ST propose de créer une boîte à outils informatique gratuite et ouverte permettant d'harmoniser ces données, de vérifier leur qualité, de les visualiser et de constituer des groupes de suivi comparables pour répondre à des questions de santé publique et de prévention.

Le projet est conçu pour respecter strictement la confidentialité. Aucune donnée réelle de travailleurs ne sera publiée. Les outils seront ouverts, mais les dossiers médicaux ne le seront pas. L'outil ne prendra aucune décision médicale automatique ; il aidera seulement les professionnels, chercheurs et institutions à mieux structurer et analyser les données disponibles dans un cadre maîtrisé.

## Annexe 2 — Équipe mobilisée et gouvernance

| Rôle                              | Responsabilités                                             | Charge indicative     | Nom / structure                 |
|-----------------------------------|-------------------------------------------------------------|-----------------------|---------------------------------|
| Chef de projet                    | Coordination, relation PDS, suivi jalons, budget, reporting | 0,15 ETP              | [À compléter]                   |
| Responsable médical santé-travail | Définitions métier, validation médicale, arbitrages         | 0,10 ETP              | Dr [À compléter]                |
| Data developer                    | ETL, schéma MCD-ST, packaging, CI/CD                        | 0,50 ETP              | Jean-Marc ALFONSI / [structure] |
| Data scientist / biostatisticien  | Contrôle qualité, cohorting, métriques, validation          | 0,30 ETP              | [À compléter]                   |
| IPRP / expert exposition          | Nomenclatures exposition, validation métier                 | 0,10 ETP              | [À compléter]                   |
| DPO / juriste RGPD                | Conformité, analyse de risques, documentation               | Prestation ponctuelle | [À compléter]                   |
| SPSTi pilotes                     | Exports, tests, retours terrain, validation d'usage         | Engagement à préciser | [SPSTi 1 / SPSTi 2]             |

La gouvernance comprendra un comité de pilotage trimestriel, un comité technique mensuel pendant les phases de développement, et des ateliers métier dédiés à la validation des définitions, des mappings et des cohortes pilotes.

## Annexe 3 — Grille de financement

Le budget détaillé figure dans le fichier Excel Budget\_MCD-ST\_BOAS\_T3.xlsx. La synthèse est reprise en section 2.5.4. Le budget total demandé est de 100 000 €, réparti entre 85 000 € de frais de personnel, 10 000 € de prestations et 5 000 € d'autres coûts directs.

## Annexe 4 — Expression de besoin SNDS

Non applicable en V1. Le projet MCD-ST relève de la thématique 3 et porte sur des données issues des SPSTi. Aucun accès à la base principale du SNDS n'est demandé dans le cadre du projet. Aucun appariement SNDS n'est prévu.

## Annexe 5 — Exemple technique et cohorte pilote

### Exemple d'entrée source

id\_salarie,annee\_naissance,sexe,poste,nuisance,type\_visite,conclusion  
123,1978,F,Aide soignante,Manutention patients,reprise,apte avec restriction  
456,1989,M,Menuisier poseur,Poussieres de bois,periodique,apte  
789,1966,F,ASH,Gestes repetitifs,pre-reprise,orientation PDP

### Exemple de sortie MCD-ST

| person_id | naissance | sexe | poste            | exposition    | visite      | conclusion  |
|-----------|-----------|------|------------------|---------------|-------------|-------------|
| P_xxx123  | 1978      | F    | Aide soignante   | BIOMECHANIQUE | REPRISE     | APTE_RESTR. |
| P_xxx456  | 1989      | M    | Menuisier poseur | CHIMIQUE      | VIP_PERIOD. | APTE        |
| P_xxx789  | 1966      | F    | ASH              | BIOMECHANIQUE | PRE_REPRISE | ORIENT_PDP  |

### Cohorte pilote proposée

Définition : travailleurs âgés de 45 ans ou plus, suivis en 2024, exposés à des contraintes biomécaniques, ayant eu une visite de reprise ou de pré-reprise en 2024, avec restriction ou aménagement.

```
name: biomech_return_restriction_2024
population:
  min_age: 45
  index_year: 2024
visits:
  visit_type_code: [REPRISE, PRE_REPRISE]
  date_start: "2024-01-01"
  date_end: "2024-12-31"
exposures:
  exposure_category_code: [BIOMECHANIQUE]
conclusions:
  operator: OR
  restriction_flag: true
  accommodation_flag: true
```

| Étape | Critère                                              | Sortie attendue |
|-------|------------------------------------------------------|-----------------|
| 1     | Population source : travailleurs suivis par le SPSTi | N travailleurs  |
| 2     | Âge ≥ 45 ans à l'année index 2024                    | N1 travailleurs |
| 3     | Visite de REPRISE ou PRE_REPRISE en 2024             | N2 travailleurs |
| 4     | Exposition biomécanique documentée                   | N3 travailleurs |
| 5     | Restriction ou aménagement                           | Cohorte finale  |

## Annexe 6 — Références et documents sources

Les références et documents sources sont regroupés dans cette annexe, conformément à la notice explicative qui demande de renvoyer les références et liens en annexe.

| Référence                                                      | Utilisation dans le dossier                                                                               |
|----------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| Notice explicative de la démarche — AMI BOAS n°10              | Structuration du dossier selon le parcours thématiques 2 & 3.                                             |
| Cahier des charges — Appel à manifestation d'intérêt BOAS n°10 | Positionnement en thématique 3, critères d'éligibilité, exigences open source, financement et calendrier. |
| Budget_MCD-ST_BOAS_T3.xlsx                                     | Synthèse financière, budget détaillé, calendrier, équipe et hypothèses.                                   |
| Dossier_candidature_MCD-ST_BOAS_T3.docx initial                | Base rédactionnelle du projet, consolidée et restructurée dans la présente version.                       |

## Annexe 7 — Checklist de conformité avant dépôt

| Point à vérifier                                                               | Statut recommandé                     |
|--------------------------------------------------------------------------------|---------------------------------------|
| Porteur chef de file personne morale enregistrée en France                     | À confirmer                           |
| SIRET et obligations fiscales/sociales à jour                                  | À compléter / confirmer               |
| Tous les paragraphes du parcours thématique 2/3 renseignés                     | Renseigné dans le présent dossier     |
| Budget inférieur ou égal au plafond thématique 3                               | 100 000 €                             |
| Durée inférieure ou égale à 24 mois                                            | 24 mois                               |
| Aucun démarrage des travaux avant convention                                   | À confirmer par le porteur            |
| Absence de financement public redondant pour la même assiette                  | À confirmer par le porteur            |
| Code, prétraitements, documentation et méthode d'évaluation mis en open source | Prévu                                 |
| Annexe équipe jointe                                                           | Incluse / à compléter nominativement  |
| Annexe financière Excel jointe                                                 | Budget_MCD-ST_BOAS_T3.xlsx            |
| EDB SNDS                                                                       | Non applicable en V1                  |
| Lettre d'intention institutionnelle                                            | Recommandée / à joindre si disponible |

Fin du dossier.